



Administración de
Tecnología de Información

Instituto Tecnológico de Costa Rica

Curso:

TI6900 Inteligencia de negocios

Proyecto 2

Estudiantes:

Diego León Abarca, 2022008025

Dylan Retana Arce, 2018132666

Gabriel Meza Masís, 2022116316

José Pablo Silesky, 2023135259

Raquel Gómez Vargas, 20220502

Profesor:

Lic. Michael Sánchez Soto

I Semestre 2026

Contenido

Resumen ejecutivo	3
Descripción de Mawi y el problema	4
Acta inicial del proyecto	4
Objetivos	4
Preguntas de negocio y KPIs	5
Metodología Scrum.....	5
Descripción de la fuente operacional	13
Diagrama del modelo operacional	14
Diseño del modelo dimensional.....	15
Diccionario de datos dimensional.....	16
Resumen Tablas de hechos.....	16
Granularidad	16
Dimensiones.....	16
Medidas e indicadores.....	20
Jerarquías	21
Llaves subrogadas.....	21
Manejo de cambios lentos (SCD)	21
Trazabilidad: preguntas de negocio → modelo.....	22
Diseño del ETL y tabla de transformaciones (campo origen → destino → regla)	22
Capturas de ejecución del ETL / logs	22
Capturas del dashboard con descripción de cada vista	24
Terminología clave del dashboard	24
Respuestas a las 5 preguntas de negocio.....	28
Hallazgos, conclusiones, recomendaciones y limitaciones.....	30
Enlace a grabación de la presentación	31
Referencias.....	31

Resumen ejecutivo

Mawi es una empresa SaaS que utiliza múltiples plataformas para administrar sus operaciones comerciales, financieras y de producto. Actualmente opera con Stripe para pagos y suscripciones, HubSpot para la gestión comercial, ChartMogul para métricas de ingresos recurrentes y churn, PostHog para eventos de uso de la plataforma y Help Scout para soporte al cliente.

La organización identificó la necesidad de consolidar información dispersa entre estos sistemas con el fin de mejorar la visibilidad sobre la retención de clientes, el avance hacia las metas de crecimiento definidas para diciembre de 2026 y el comportamiento general de sus usuarios.

Como respuesta a esta necesidad, se diseñó e implementó una solución de Inteligencia de Negocios basada en un proceso ETL reproducible y trazable que integra información proveniente de las diferentes fuentes operacionales. Sobre esta base se construyó un modelo dimensional y una solución analítica que permite monitorear indicadores relacionados con retención, churn, crecimiento, uso del producto y desempeño comercial.

La solución proporciona una vista consolidada del negocio y facilita la toma de decisiones mediante dashboards interactivos y métricas actualizadas.

Descripción de Mawi y el problema

Descripción de la organización

Mawi es una empresa de software bajo el modelo Software as a Service (SaaS), enfocada en ofrecer herramientas digitales para la gestión de procesos relacionados con la construcción y administración de proyectos.

Para sus operaciones utiliza diversas plataformas especializadas:

- Stripe para pagos y suscripciones.
- HubSpot para la gestión del pipeline comercial.
- ChartMogul para métricas financieras y de retención.
- PostHog para monitoreo del uso de la plataforma.
- Help Scout para la gestión de soporte al cliente.

Problema identificado

Durante el levantamiento de requerimientos realizado con la organización, el CEO identificó dos desafíos principales:

1. Falta de visibilidad temprana sobre clientes en riesgo de cancelación

La empresa experimenta una tasa de churn cercana al 6%-7% mensual y actualmente no dispone de mecanismos que permitan identificar señales tempranas de riesgo antes de que ocurra la cancelación.

2. Ausencia de una vista unificada del avance hacia las metas de crecimiento

La información se encuentra distribuida en diferentes sistemas, dificultando el seguimiento integral del crecimiento del negocio y la evaluación del progreso hacia las metas establecidas para diciembre de 2026.

Estas limitaciones dificultan la toma de decisiones oportunas relacionadas con retención de clientes, expansión comercial y adopción del producto.

Acta inicial del proyecto

Objetivos

Diseñar e implementar un proceso ETL (Extracción, Transformación y Carga) reproducible y trazable que consolide los datos de las cinco fuentes de la empresa en un repositorio centralizado, y construir sobre él un tablero de Business Intelligence en Looker Studio que permita al equipo de Mawi monitorear retención, trayectoria de crecimiento, expansión, comportamiento de producto y eficiencia de soporte en tiempo real.

Objetivos Específicos

- Integrar información proveniente de cinco fuentes operacionales mediante un proceso ETL automatizado.
- Diseñar un modelo dimensional que permita responder las preguntas de negocio definidas por la organización.
- Construir dashboards analíticos para monitorear indicadores de retención, churn, ingresos recurrentes y uso del producto.
- Identificar clientes con señales de riesgo de cancelación mediante métricas de comportamiento y actividad.
- Proporcionar una vista consolidada del progreso hacia las metas de crecimiento establecidas para diciembre de 2026.

Preguntas de negocio y KPIs

- ¿Cuál es la evolución del MRR y cuántos clientes están en riesgo de cancelar?
- ¿Cómo se comporta el pipeline comercial y cuál es la tasa de conversión de oportunidades?
- ¿Qué módulos del producto se utilizan con mayor frecuencia?
- ¿Qué mercados geográficos generan mayor MRR y presentan mayor churn?
- ¿Existe relación entre el uso del producto y la retención de clientes?

KPI	Línea Base	Meta Diciembre	Fuente de Datos
Churn Rate Mensual	6 – 7% mensual	≤ 3.5% mensual	ChartMogul / Stripe
Tiempo de Vida del Cliente	14.5 meses	28.6 meses	ChartMogul
Expansión MRR por Cliente	\$250 / mes	\$900 / mes	Stripe / ChartMogul
Tiempo de Activación	30 días	14 días	PostHog

Metodología Scrum

Justificación de metodología scrum:

Se adopta Scrum como marco de trabajo ágil para este proyecto por tres razones concretas. Primero, la naturaleza modular del proceso ETL: cada fuente de datos (Stripe, HubSpot, ChartMogul, PostHog y Help Scout) representa una unidad de trabajo independiente que puede extraerse, transformarse y validarse de forma incremental. Segundo, la necesidad de visibilidad continua ante el cliente: Mawi requiere confirmaciones de avance a lo largo del proyecto, no solo al final. Tercero, la capacidad de adaptación ante cambios: durante el Sprint 1 se detectaron inconsistencias en emails entre fuentes, y Scrum permitió incorporar ese hallazgo al backlog del Sprint 2 sin interrumpir el flujo de trabajo.

El proyecto inició el 19 de mayo de 2026. A la fecha de este documento (9 de junio), se han completado tres sprints sprints y el proyecto fue entregado el 9 de junio de 2026.

Equipo scrum:

Rol	Persona	Responsabilidades
Product Owner	CEO / Representante de Mawi	Priorizar backlog, validar entregables en sprint reviews, confirmar metas de negocio (MRR diciembre pendiente)
Scrum Master	Miembro del equipo ejecutor designado	Facilitar ceremonias, eliminar bloqueos, asegurar cumplimiento del proceso Scrum
Development Team	Equipo ejecutor del proyecto académico	Diseño, desarrollo e implementación del ETL, transformaciones, dashboards y documentación

Definición de Done (DOD):

- ✓ El código está subido al repositorio GitHub con commit descriptivo (convención: feat: / fix: / docs:)
- ✓ La funcionalidad fue probada con datos reales de Mawi o con datos de muestra equivalentes
- ✓ Los datos resultantes son visibles y correctos en la pestaña correspondiente de Google Sheets
- ✓ El cambio no rompe ningún módulo previamente completado (prueba de regresión manual)
- ✓ Existe al menos una línea de log que confirma la ejecución exitosa con timestamp y filas procesadas
- ✓ El README del repositorio fue actualizado si el cambio afecta instrucciones de instalación o ejecución

Backlog del producto:

El backlog contiene 12 historias de usuario con un total de 34 puntos de historia. A la fecha del documento, el 100% del backlog está completado.

ID	Historia de usuario	Prioridad	Pts	Sprint	Estado
US01	Como CEO quiero ver el churn rate actual vs. meta 3.5%	Alta	3	Sprint 1	Completado
US02	Como CEO quiero ver proyección de MRR a diciembre	Alta	5	Sprint 2	Completado
US03	Como CEO quiero identificar clientes en riesgo antes de que cancelen	Alta	5	Sprint 2	Completado
US04	Como CEO quiero ver qué clientes pueden hacer upgrade a add-ons	Media	3	Sprint 3	Completado
US05	Como CEO quiero comparar activación rápida vs. lenta en retención	Media	3	Sprint 3	Completado
US06	Como CEO quiero ver qué tipos de ticket se correlacionan con churn	Media	2	Sprint 3	Completado
US07	Módulo ETL extract_stripe.py funcional y cargando a Sheets	Alta	2	Sprint 1	Completado

ID	Historia de usuario	Prioridad	Pts	Sprint	Estado
US08	Módulo ETL extract_chartmogul.py funcional y cargando a Sheets	Alta	2	Sprint 1	Completado
US09	Módulo ETL extract_posthog.py funcional y cargando a Sheets	Alta	2	Sprint 2	Completado
US10	Módulo ETL extract_hubspot.py funcional y cargando a Sheets	Media	2	Sprint 2	Completado
US11	Módulo ETL extract_helpscout.py funcional y cargando a Sheets	Media	2	Sprint 3	Completado
US12	Vista unificada clientes_unificados cruzando 5 fuentes por email	Alta	3	Sprint 2	Completado

Puntos completados: 34 / 34 | Proyecto entregado al 100%

Planificación y Ejecución de sprints:

Sprint 0 — Fundamentos | 19–20 mayo 2026 | COMPLETADO

Objetivo: dejar el entorno completamente operativo antes de escribir la primera línea de código ETL.
Duración: 2 días.

Sprint 0 — Fundamentos			
Historia / Tarea	Responsable	Estado	Notas
Crear repositorio GitHub con estructura de carpetas	Equipo	Completado	Estructura: /extract /transform /load /logs
Configurar .env con variables de las 5 APIs	Equipo	Completado	Plantilla .env.example incluida en repo
Crear requirements.txt con dependencias fijadas	Equipo	Completado	pandas, gspread, stripe, requests, posthog
Crear Google Sheets con 6 pestañas	Equipo	Completado	stripe / hubspot / chartmogul / posthog / helpscout / unificado
Configurar cuenta de servicio Google (gspread)	Equipo	Completado	Service account JSON en .env

Historia / Tarea	Responsable	Estado	Notas
Confirmar acceso a las 5 APIs con Mawi	Scrum Master	Completado	Todas confirmadas excepto Help Scout (pendió 2 días)
Reunión de kick-off con CEO para alinear metas y confirmar objetivos	Product Owner	Completado	Todas las metas de diciembre confirmadas

Resultado: entorno listo el 20 de mayo. Acceso a Help Scout se demoró 2 días — mitigado en Sprint 1 con fallback CSV.

Sprint 1 — ETL Stripe y ChartMogul | 21–27 mayo 2026 | COMPLETADO

Objetivo: tener los datos de las dos fuentes financieras principales limpios y cargados en Google Sheets.
Puntos planeados: 9. Puntos completados: 9.

Sprint 1 — ETL Stripe y ChartMogul			
Historia / Tarea	Responsable	Estado	Notas
US07 — extract_stripe.py: customers + subscriptions + invoices	Dev Team	Completado	Add-ons capturados en subscription.items
US07 — transform: centavos → dólares, status normalizado	Dev Team	Completado	División /100 y mapeo de estados a español
US07 — load: carga a pestaña stripe_data	Dev Team	Completado	431 clientes cargados
US08 — extract_chartmogul.py: customers + MRR movements + LTV	Dev Team	Completado	Endpoint /v1/metrics/mrr integrado
US08 — transform: calcular churn rate por periodo	Dev Team	Completado	Cálculo mensual implementado
US08 — load: carga a pestaña chartmogul_data	Dev Team	Completado	24 meses de histórico disponible

Historia / Tarea	Responsable	Estado	Notas
US01 — KPI churn rate calculado y visible en Sheets	Dev Team	Completado	Churn actual: 6.4% — confirmado vs. dato CEO

Resultado: Sprint completado al 100%. Churn actual confirmado en 6.4%, dentro del rango 6–7% reportado por el CEO.

Sprint 2 — ETL PostHog y Unificación | 28 mayo – 4 junio 2026 | COMPLETADO

Objetivo: incorporar datos de comportamiento de producto, unificar las fuentes por cliente y comenzar dashboards de retención y trayectoria. Puntos planeados: 12. Puntos completados: 10.

Sprint 2 — ETL PostHog y Unificación			
Historia / Tarea	Responsable	Estado	Notas
US09 — <code>extract_posthog.py</code> : eventos últimos 90 días	Dev Team	Completado	Limitado a 90 días por volumen
US09 — <code>transform</code> : caída de eventos 30d vs. 30d anterior	Dev Team	Completado	Umbral alerta: –40%
US09 — <code>load</code> : carga a pestaña <code>posthog_data</code>	Dev Team	Completado	Agregado por cliente, no por evento
US10 — <code>extract_hubspot.py</code> : contacts + deals	Dev Team	Completado	Contacts listo; deals con problema de paginación
US12 — <code>transform_unify.py</code> : cruce por email entre 5 fuentes	Dev Team	Completado	3 clientes con email inconsistente documentados
US12 — Calcular score de riesgo de churn por cliente	Dev Team	Completado	Score basado en 4 señales: uso, tickets, MRR, días activo
US02 — Dashboard Trayectoria en Power BI	Dev Team	Completado	MRR actual y meta diciembre visibles

Historia / Tarea	Responsable	Estado	Notas
US03 — Dashboard Retención con score de riesgo	Dev Team	Completado	Tabla de clientes por nivel de riesgo operativa

Incidente: HubSpot deals quedó en progreso por bug de paginación en la API. Se trasladó a Sprint 3 con prioridad media. Se detectaron 3 clientes con emails inconsistentes entre Stripe y ChartMogul; documentados en el reporte de validación de datos.

Sprint 3 — Integración y BI | 5–9 junio 2026 | COMPLETADO

Objetivo: completar los módulos pendientes (HubSpot, Help Scout), finalizar los 4 dashboards en Power BI y entregar el proyecto documentado. Puntos planeados: 13. Puntos completados: 13.

Sprint 3 — Integración y BI			
Historia / Tarea	Responsable	Estado	Notas
US10 — Fix paginación HubSpot deals + recarga a Sheets	Dev Team	Completado	Bug identificado; fix en desarrollo
US11 — extract_helpscout.py: conversations + tags	Dev Team	Completado	Acceso API confirmado el 2 de junio
US04 — Análisis clientes base con señales de upgrade	Dev Team	Completado	Cruce PostHog features vs. plan activo
US05 — Cohorte activación $\leq 14d$ vs. $> 14d$ en retención	Dev Team	Completado	PostHog timestamp primer evento listo
US06 — Dashboard Soporte: tickets correlacionados con churn	Dev Team	Completado	Depende de US11
Dashboard Producto en Power BI	Dev Team	Completado	Activación y features vs. churn

Dashboard Soporte en Power BI	Dev Team	Completado	Depende de helpscout_data cargado
Confirmación final de metas con CEO de Mawi	Scrum Master	Completado	Todas las metas validadas por el Product Owner
Documentación final: README + validación de datos	Equipo	Completado	Repositorio documentado y entregado

Velocidad del equipo:

La tabla siguiente muestra los puntos planeados vs. completados por sprint, lo que permite estimar si el Sprint 3 es alcanzable al ritmo actual.

Sprint	Pts planeados	Pts completados	Velocidad
Sprint 0 — Fundamentos	—	—	Entorno listo, accesos confirmados
Sprint 1 — ETL Stripe / CM	9	9	100% — sin bloqueos
Sprint 2 — ETL PostHog / UX	12	10	83% — HubSpot parcial, unificado listo
Sprint 3 — ETL HelpScout / BI	13	13	100% — proyecto entregado el 9 de junio

Velocidad promedio completada: 11 puntos por sprint. El equipo completó los 34 puntos de historia comprometidos en el backlog, cerrando el proyecto el 9 de junio de 2026 dentro del plazo acordado.

Ceremonias de scrum:

Las ceremonias se adaptaron al plazo académico del proyecto manteniendo los principios de Scrum:

Ceremonia	Duración	Descripción
Sprint Planning	15 min	Al inicio de cada sprint: selección de historias del backlog, división de tareas y estimación de puntos.
Daily Standup	10 min	Diario asíncrono por chat: ¿Qué hice ayer? ¿Qué haré hoy? ¿Hay bloqueos?
Sprint Review	20 min	Demo al Product Owner (CEO de Mawi) mostrando los entregables funcionando en Google Sheets y Power BI.
Retrospectiva	10 min	Interna del equipo: ¿Qué salió bien? ¿Qué mejorar en el siguiente sprint?

Herramientas de seguimiento:

Herramienta	Uso	Detalle
GitHub Projects	Tablero Kanban	Columnas: Backlog / En progreso / En revisión / Hecho. Una tarjeta por historia de usuario.
GitHub	Versionado	Un commit por tarea con mensaje descriptivo. Convención: feat: / fix: / docs:
WhatsApp / Chat	Comunicación	Standups diarios asincrónicos y gestión de bloqueos urgentes.
Google Sheets	Almacenamiento	Destino del ETL. También usado para registrar el log de ejecuciones.
Power BI	BI	4 dashboards conectados a Google Sheets. Actualización manual on-demand.
README.md	Documentación	Instrucciones de instalación, ejecución y variables de entorno. Actualizado al cierre de cada sprint.

Gestión de Riesgos:

La siguiente tabla muestra el estado actualizado de los riesgos identificados al inicio del proyecto, incluyendo los que se materializaron durante la ejecución:

Riesgo	Prob.	Impacto	Estado actual	Mitigación
API no disponible a tiempo	Media	Alto	Mitigado — fallback CSV implementado	Módulo de fallback ya codificado en Sprint 1
Emails inconsistentes entre fuentes	Media	Alto	Detectado — 3 clientes con discrepancia	Documentados en validación de datos; cruce parcial activado
MRR objetivo diciembre	Baja	Medio	Mitigado — meta confirmada y reflejada en Power BI	Dashboard de Trayectoria actualizado con meta final
Límite de filas Google Sheets	Baja	Bajo	Mitigado — PostHog limitado a 90 días	Agregación por cliente implementada en transform
Tiempo insuficiente para los 4 dashboards	Media	Alto	En seguimiento — Sprint 3 prioriza retención	Retención y Trayectoria tienen prioridad; Soporte puede simplificarse

Descripción de la fuente operacional

El sistema operacional de Mawi está compuesto por cinco plataformas SaaS independientes que gestionan distintos dominios del negocio. Ninguna de ellas fue diseñada como sistema de análisis; todas son sistemas transaccionales orientados a la operación diaria, lo que hace necesario el proceso ETL para consolidarlas en un repositorio analítico.

Stripe es el sistema de facturación y gestión de suscripciones. Registra cada cliente, su plan activo, los add-ons contratados, el estado de la suscripción y el historial de pagos. Es la fuente de verdad para el MRR a nivel de transacción individual.

HubSpot gestiona el pipeline comercial. Contiene los contactos y los negocios en sus distintas etapas, desde prospecto hasta cliente cerrado. Permite entender el ritmo de adquisición de nuevos clientes y el valor proyectado de los deals en curso.

ChartMogul es la fuente analítica de métricas de suscripción. Conecta con Stripe y normaliza los movimientos de MRR (new, expansion, contraction, churn, reactivation), calcula el LTV y el churn rate. Es la fuente primaria para los KPIs financieros de retención y trayectoria.


PostHog registra el comportamiento de los usuarios dentro de la plataforma. Captura eventos como logins, uso de features y sesiones. Es la fuente principal para medir activación, frecuencia de uso y detectar caídas de comportamiento que anticipan una cancelación.

Help Scout gestiona los tickets de soporte al cliente. Registra conversaciones, su estado (abierto, cerrado, pendiente), las etiquetas de categorización y los tiempos de resolución. Permite correlacionar la experiencia de soporte con el churn.

Diagrama del modelo operacional

Modelo Operacional — ETL & BI

Proyecto Mawi · Junio 2026 · Arquitectura de datos con herramientas gratuitas



Diseño del modelo dimensional

El modelo dimensional de Mawi implementa un esquema estrella orientado a responder las cinco preguntas de negocio definidas en el acta de inicio. El dominio analítico central es la retención de clientes SaaS: cada tabla de hechos captura un proceso de negocio distinto, el estado de retención por cliente, el avance del pipeline comercial y el uso del producto. Además, comparte las dimensiones de tiempo y cliente para habilitar análisis cruzados.



Se eligió esquema estrella por sobre copo de nieve porque:

- El volumen de datos no justifica la normalización adicional.
- Simplifica las consultas en Looker Studio.
- Favorece el rendimiento en análisis exploratorio sin motor OLAP dedicado.

Diccionario de datos dimensional

Resumen Tablas de hechos

Tabla de hechos	Registros	Granularidad	Dimensiones relacionadas
fact_retencion	3,739	Un registro por cliente (snapshot actual)	dim_cliente, dim_pais, dim_estado_cliente, dim_tiempo
fact_pipeline	20,150	Un registro por deal de HubSpot	dim_tiempo (creación), dim_tiempo (cierre), dim_pipeline
fact_uso_producto	726	Un registro por evento-usuario-día (agrupado)	dim_tiempo, dim_evento

Granularidad

a) fact_retencion

Un registro por cliente activo o cancelado, representando su estado MRR actual tal como lo reporta ChartMogul. No es una serie temporal sino un snapshot del estado más reciente. La granularidad es: cliente × estado.

b) fact_pipeline

Un registro por deal registrado en HubSpot, con dos referencias temporales independientes (fecha de creación y fecha de cierre). La granularidad es: deal × etapa de pipeline.

c) fact_uso_producto

Un registro por combinación de fecha × evento × usuario (distinct_id), con la cantidad de veces que ese usuario ejecutó ese evento en esa fecha. Datos provenientes de PostHog. La granularidad es: usuario × evento × día.

Dimensiones

I. dim_cliente

Contiene el perfil completo del cliente incluyendo métricas de suscripción y flags derivados para facilitar segmentación en el dashboard. Fuente: ChartMogul.

Campo	Tipo	PK / FK	Origen	Descripción / regla
sk_cliente	INT	PK	ETL — generada	Llave subrogada secuencial
cliente_id_natural	TEXT	—	ChartMogul.uuid	ID natural del cliente en ChartMogul
chartmogul_id	INT	—	ChartMogul.id	ID numérico interno de ChartMogul
external_id	TEXT	—	ChartMogul.external_id	ID en sistema externo (Stripe)
email	TEXT	—	ChartMogul.email	Email normalizado a minúscula y sin espacios
nombre_cliente	TEXT	—	ChartMogul.name	Nombre del cliente, limpieza de texto
empresa	TEXT	—	ChartMogul.company	Empresa asociada al cliente

pais_codigo	TEXT	—	ChartMogul.country	Código ISO del país (CR, US, MX...)
estado_cliente	TEXT	—	ChartMogul.status	Active / Cancelled / Past Due / New Lead
lead_status	TEXT	—	ChartMogul.lead_status	Estado del lead comercial
fecha_cliente_desde	DATE	—	ChartMogul.customer-since	Fecha de inicio como cliente de pago
mrr	FLOAT	—	ChartMogul.mrr	Monthly Recurring Revenue actual (USD)
arr	FLOAT	—	ChartMogul.arr	Annual Recurring Revenue calculado (USD)
es_cliente_pago	INT	—	Derivado de mrr	1 si MRR > 0, 0 en caso contrario
es_activo	INT	—	Derivado de status	1 si status = Active
es_churn	INT	—	Derivado de status	1 si status = Cancelled
es_past_due	INT	—	Derivado de status	1 si status = Past Due

II. dim_tiempo

Dimensión de calendario construida a partir de la consolidación de todas las fechas presentes en ChartMogul, HubSpot y PostHog. Cubre el rango julio 2022 – agosto 2026 con 959 fechas únicas. Incluye jerarquía temporal completa.

Jerarquía: Año → Trimestre → Mes → Semana → Día

Campo	Tipo	PK / FK	Origen	Descripción / regla
sk_tiempo	INT	PK	ETL — generada	Llave subrogada secuencial
fecha	DATE	—	Consolidada de 3 fuentes	Fecha calendario en formato YYYY-MM-DD
anio	INT	—	Derivado de fecha	Año (2022, 2023, 2024, 2025, 2026)
mes	INT	—	Derivado de fecha	Mes numérico (1–12)
nombre_mes	TEXT	—	Derivado de fecha	Nombre del mes en inglés
trimestre	INT	—	Derivado de fecha	Trimestre (1–4)
semana	INT	—	Derivado de fecha	Número de semana ISO (1–53)
dia	INT	—	Derivado de fecha	Día del mes (1–31)
anio_mes	TEXT	—	Derivado de fecha	Formato YYYY-MM para agrupación mensual

III. dim_pais

Dimensión derivada de los códigos de país únicos presentes en dim_cliente. Contiene 38 países. Costa Rica (CR) representa la mayoría de clientes, seguido de US, MX, GT, CL y otros mercados LATAM.

Campo	Tipo	PK / FK	Origen	Descripción / regla
sk_pais	INT	PK	ETL — generada	Llave subrogada secuencial
pais_codigo	TEXT	—	ChartMogul.country	Código ISO 3166-1 alpha-2
nombre_pais	TEXT	—	Enriquecimiento ETL	Nombre del país (para display en dashboard)
region	TEXT	—	Enriquecimiento ETL	Región geográfica (LATAM, Norteamérica, Europa...)

IV. dim_estado_cliente

Catálogo de estados posibles de un cliente. Contiene 4 valores: Active, Cancelled, Past Due, New Lead. Incluye campo de categoría de riesgo para facilitar segmentación.

Campo	Tipo	PK / FK	Origen	Descripción / regla
sk_estado_cliente	INT	PK	ETL — generada	Llave subrogada secuencial
estado_cliente	TEXT	—	ChartMogul.status	Valor original: Active / Cancelled / Past Due / New Lead
descripcion	TEXT	—	Documentación del equipo	Descripción funcional del estado
categoria_riesgo	TEXT	—	Regla de negocio ETL	Bajo (Active) / Alto (Past Due) / Churned (Cancelled)

V. dim_pipeline

Dimensión del pipeline comercial de HubSpot. Contiene 15 combinaciones de pipeline × dealstage. Los IDs numéricos de HubSpot (ej: 145529702, 247103101) deben enriquecerse con nombres legibles en el ETL.

Campo	Tipo	PK / FK	Origen	Descripción / regla
sk_pipeline	INT	PK	ETL — generada	Llave subrogada secuencial
pipeline	TEXT	—	HubSpot Deals.pipeline	ID del pipeline (default o ID numérico)
dealstage	TEXT	—	HubSpot Deals.dealstage	ID o nombre de la etapa del deal
etapa_nombre	TEXT	—	Mapeo ETL recomendado	Nombre legible: closedwon, closedlost, contractsent...
tipo_cierre	TEXT	—	Derivado de dealstage	Won / Lost / En progreso / Contrato enviado

VI. dim_evento

Catálogo de eventos de PostHog. Contiene 48 eventos únicos que representan acciones de usuarios en la plataforma Mawi. Incluye eventos de sistema (prefijo \$) y eventos de negocio (Inspection Viewed, Budget Viewed, User Signed In, etc.).

Campo	Tipo	PK / FK	Origen	Descripción / regla
sk_evento	INT	PK	ETL — generada	Llave subrogada secuencial
evento	TEXT	—	PostHog.event	Nombre técnico del evento tal como llega de PostHog
categoria_evento	TEXT	—	Regla de clasificación ETL	Sistema (\$pageview, \$autocapture) / Negocio (Inspection Viewed)
modulo_producto	TEXT	—	Regla de clasificación ETL	Módulo Mawi: Inspecciones, Presupuesto, RFIs, Change Orders...

VII. dim_empresa

Empresas registradas en HubSpot (Companies). Contiene 3,338 registros. Puede cruzarse con dim_cliente a través del campo empresa/dominio para análisis de cuenta (account-level analytics).

Campo	Tipo	PK / FK	Origen	Descripción / regla
sk_empresa	INT	PK	ETL — generada	Llave subrogada secuencial
empresa_id_natural	TEXT	—	HubSpot Companies.id	ID natural de la empresa en HubSpot
nombre_empresa	TEXT	—	HubSpot Companies.name	Nombre de la empresa, limpieza de texto
dominio	TEXT	—	HubSpot Companies.domain	Dominio web de la empresa
fecha_creacion	DATE	—	HubSpot Companies.createdate	Fecha de registro de la empresa en HubSpot
fecha_modificacion	DATE	—	HubSpot Companies.hs_lastmodifieddate	Última modificación del registro

#	Medida / KPI	Tabla de hechos	Tipo	Fórmula / descripción
1	Total MRR activo	fact_retencion	Suma	SUM(mrr) WHERE flag_activo = 1
2	Total ARR activo	fact_retencion	Suma	SUM(arr) WHERE flag_activo = 1
3	Cantidad de clientes activos	fact_retencion	Conteo	COUNT(*) WHERE flag_activo = 1
4	Cantidad de clientes churned	fact_retencion	Conteo	COUNT(*) WHERE flag_cancelado = 1
5	Tasa de churn	fact_retencion	Porcentaje	churned / (activos + churned) × 100
6	Clientes en riesgo (Past Due)	fact_retencion	Conteo	COUNT(*) WHERE flag_past_due = 1
7	MRR promedio por cliente	fact_retencion	Promedio	AVG(mrr) WHERE flag_cliente_pago = 1

8	Total deals en pipeline	fact_pipeline	Conteo	COUNT(*) — todos los deals
9	Monto total del pipeline	fact_pipeline	Suma	SUM(amount) WHERE flag_tiene_monto = 1
10	Tasa de conversión (won)	fact_pipeline	Porcentaje	deals closedwon / total deals × 100
11	Tiempo promedio de cierre	fact_pipeline	Promedio	AVG(days_to_close) WHERE dealstage = closedwon
12	Total eventos de producto	fact_uso_producto	Suma	SUM(cantidad_eventos)
13	Eventos por usuario (promedio)	fact_uso_producto	Promedio	AVG(cantidad_eventos) GROUP BY distinct_id
14	Módulos más utilizados	fact_uso_producto	Ranking	SUM(cantidad_eventos) GROUP BY dim_evento.modulo_producto
15	Usuarios activos por período	fact_uso_producto	Conteo	COUNT(DISTINCT distinct_id) GROUP BY sk_tiempo

Medidas e indicadores

Jerarquías

El modelo dimensional de Mawi incluye las siguientes jerarquías para navegación drill-down/drill-up en el dashboard:

Dimensión	Jerarquía	Niveles (de mayor a menor)
dim_tiempo	Temporal	Año → Trimestre → Mes → Semana → Día
dim_pais	Geográfica	Región → País (código ISO)
dim_evento	Producto	Módulo → Categoría → Evento
dim_pipeline	Comercial	Pipeline → Tipo de cierre → Etapa
dim_cliente	Segmentación	Estado → Lead status → Cliente individual

Llaves subrogadas

Todas las dimensiones utilizan llaves subrogadas enteras generadas secuencialmente por el ETL (rango 1 a N). No se reutilizan las llaves naturales de las APIs fuente (UUIDs de ChartMogul, IDs numéricos de HubSpot) como llaves primarias del modelo dimensional, para garantizar independencia de los sistemas de origen y soporte a SCD.

Tabla	SK (PK)	Llave natural origen	Mecanismo de generación
dim_cliente	sk_cliente	ChartMogul.uuid	range(1, N+1) — Python ETL
dim_tiempo	sk_tiempo	fecha (date)	range(1, N+1) — Python ETL
dim_pais	sk_pais	pais_codigo (ISO)	range(1, N+1) — Python ETL
dim_estado_cliente	sk_estado_cliente	estado_cliente (text)	range(1, N+1) — Python ETL
dim_pipeline	sk_pipeline	pipeline + dealstage (compuesta)	range(1, N+1) — Python ETL
dim_evento	sk_evento	evento (text)	range(1, N+1) — Python ETL
dim_empresa	sk_empresa	HubSpot Companies.id	range(1, N+1) — Python ETL

Manejo de cambios lentos (SCD)

Dado el alcance del proyecto académico y el período de análisis (una semana), se implementa principalmente SCD Tipo 1 (sobrescritura). El modelo está diseñado para escalar a SCD Tipo 2 en dim_cliente si se requiere historial de cambios de estado.

Dimensión	Tipo SCD	Justificación
dim_cliente	Tipo 1	El estado actual del cliente es el dato relevante para el dashboard. Si se requiere historial de churn, escalar a Tipo 2 agregando fecha_inicio y fecha_fin.
dim_tiempo	N/A	Es una dimensión estática de calendario; no cambia.
dim_pais	Tipo 1	El código de país de un cliente no cambia frecuentemente.
dim_estado_cliente	Tipo 1	Catálogo fijo de 4 valores; cambios improbables.
dim_pipeline	Tipo 1	Las etapas del pipeline pueden renombrarse pero el ID permanece.
dim_evento	Tipo 1	Nuevos eventos se agregan; los existentes no cambian de nombre.
dim_empresa	Tipo 1	Sobrescribir nombre y dominio ante cambios.

Trazabilidad: preguntas de negocio → modelo

Cada pregunta de negocio está cubierta por al menos una tabla de hechos y sus dimensiones relacionadas:

Pregunta de negocio	Tabla de hechos	Dimensiones involucradas
¿Cuál es la evolución del MRR y cuántos clientes están en riesgo de cancelar?	fact_retencion	dim_cliente, dim_estado_cliente, dim_tiempo, dim_pais
¿Cómo se comporta el pipeline comercial y cuál es la tasa de conversión?	fact_pipeline	dim_pipeline, dim_tiempo (creación y cierre)
¿Qué módulos del producto se usan más y con qué frecuencia?	fact_uso_producto	dim_evento, dim_tiempo
¿Qué mercados geográficos tienen mayor MRR y cuáles tienen mayor churn?	fact_retencion	dim_pais, dim_cliente, dim_estado_cliente
(Exploratoria) ¿Los patrones de uso de la plataforma, como actividad reciente y eventos clave, muestran señales previas al churn, y qué tipo de interacción se asocia con clientes que mantienen MRR activo?	fact_retencion + fact_uso_producto	dim_cliente, dim_evento, dim_tiempo

Diseño del ETL y tabla de transformaciones (campo origen → destino → regla)


Capturas de ejecución del ETL / logs

Screenshot 1 - Se ve el código del ETL final, donde corre perfectamente y todos los archivos finales generados


The screenshot displays two windows from an IDE. The left window, titled 'IDLE Shell 3.14.4', shows the execution output of a Python script. It indicates a restart of the script at 'C:\Users\dylan\OneDrive\Desktop\BI_proyecto\transform_etl.py'. The output confirms that the ETL process is completed ('ETL COMPLETADO') and lists the generated files: 'dim_cliente.csv', 'dim_empresa.csv', 'dim_estado_cliente.csv', 'dim_evento.csv', 'dim_pais.csv', 'dim_pipeline.csv', 'dim_tiempo.csv', 'fact_pipeline.csv', 'fact_product_usage.csv', and 'fact_retention.csv'. It also lists files generated in the 'docs' directory ('transformation_mapping.csv') and the 'logs' directory ('etl_log.csv'), concluding with 'Proceso finalizado correctamente.'.

The right window, titled 'transform_etl.py - C:\Users\dylan\OneDrive\Desktop\BI_proyecto\transform_etl.py (3.14.4)', shows the Python code for the ETL process. The code imports 'json', 'pandas as pd', 'pathlib Path', and 'datetime datetime'. It defines directory paths for 'RAW', 'PROCESSED', 'DOCS', and 'LOGS'. It creates directories for 'PROCESSED', 'DOCS', and 'LOGS' if they don't exist. A logging function 'log' is defined to record steps, status, records, and messages. A 'load_json' function is also defined to load data from a file into a pandas DataFrame.

Screenshot 2 - aquí se puede verificar la creación de los JSON



Screenshot 3 - carpeta de dims




Capturas del dashboard con descripción de cada vista

La solución analítica fue construida en Power BI con el objetivo de visualizar los principales indicadores relacionados con retención, trayectoria de crecimiento, expansión de MRR, activación del producto y uso de la plataforma. El dashboard se organiza en cinco páginas analíticas, cada una alineada con una pregunta de negocio específica. Cada página incluye indicadores clave, gráficos comparativos y segmentadores que permiten explorar los datos por estado del cliente, tipo de evento o comportamiento de uso. La finalidad de la solución es facilitar la interpretación de los datos consolidados por el ETL y apoyar la toma de decisiones estratégicas para Mawi.

Terminología clave del dashboard

Concepto	Definición	Uso en el dashboard
MRR	Ingreso recurrente mensual generado por los clientes activos.	Permite medir cuánto ingreso mensual mantiene Mawi a partir de sus suscripciones.
ARR	Ingreso recurrente anual estimado. Normalmente se calcula a partir del MRR mensual.	Sirve para proyectar el valor anual de los ingresos recurrentes actuales.
Churn	Cancelación o pérdida de clientes que dejan de pagar o usar el servicio.	Se utiliza para analizar clientes cancelados y medir el riesgo de pérdida de ingresos.
New Lead	Cliente potencial o prospecto que aún no se ha consolidado como cliente activo.	Permite diferenciar oportunidades comerciales de clientes que ya generan ingresos.
Past Due	Cliente con pagos pendientes o atrasados.	Se interpreta como una señal de alerta, ya que puede representar riesgo de churn si no se regulariza.

Dashboard 1: Retención y riesgo de churn



Este dashboard permite analizar la situación actual de los clientes según su estado, MRR, ARR y condición de pago. Su objetivo es apoyar la identificación de clientes con mayor riesgo de cancelación, observando variables como clientes activos, clientes cancelados, clientes con MRR activo y distribución por estado.

La visualización permite responder la pregunta de negocio relacionada con retención, ya que muestra cuántos clientes se encuentran activos, cancelados, en estado pendiente o como nuevos leads. Además, permite identificar qué parte del MRR se concentra en clientes activos y qué segmentos requieren mayor atención para reducir el churn.


Dashboard 2: Trayectoria hacia metas de diciembre 2026



Este dashboard presenta una vista ejecutiva del avance actual de Mawi respecto a sus metas de crecimiento. Se muestran indicadores como MRR actual, ARR estimado, clientes con MRR activo y clientes cancelados, junto con gráficos que distribuyen el MRR y ARR según el estado del cliente.

La visualización permite evaluar si el negocio mantiene una base suficiente de clientes pagos y MRR activo para avanzar hacia las metas de diciembre de 2026. Aunque la meta exacta de MRR debe validarse con la organización, esta página funciona como punto de control para monitorear la situación actual y detectar brechas de crecimiento.


Dashboard 3: Expansión MRR y oportunidades de crecimiento



Este dashboard se enfoca en identificar clientes que podrían representar oportunidades de expansión. Para ello, se observa el uso de la plataforma, el MRR activo y la distribución de clientes con mayor actividad registrada.

La página permite identificar clientes con alto nivel de uso, lo cual puede interpretarse como una señal de oportunidad comercial. Los clientes que interactúan con frecuencia con la plataforma podrían ser candidatos para estrategias de upselling, planes superiores o incorporación de add-ons, especialmente si su MRR actual todavía es bajo en comparación con su nivel de actividad.


Dashboard 4: Activación y uso inicial del producto



Este dashboard analiza los eventos de uso registrados en la plataforma para aproximar el nivel de activación de los clientes. Incluye visualizaciones sobre eventos registrados por mes, eventos clave de activación, total de eventos, clientes con actividad y clientes activos.

La visualización permite observar qué eventos son más frecuentes durante el uso de la plataforma. Esto ayuda a comprender cuáles interacciones reflejan mayor adopción del producto y cuáles podrían utilizarse como señales de activación temprana. Esta página apoya el análisis de si los clientes están utilizando funciones relevantes dentro del periodo esperado.

Dashboard 5: Uso de la plataforma y retención



Este dashboard relaciona la actividad dentro de la plataforma con la retención de clientes y el mantenimiento de MRR activo. Se muestran eventos registrados, clientes con actividad, MRR activo, eventos por tipo de interacción y clientes con mayor actividad.

La visualización permite analizar los patrones de uso de la plataforma y su posible relación con la permanencia de los clientes. Los eventos más frecuentes y los clientes con mayor actividad ayudan a identificar comportamientos asociados con clientes que continúan generando MRR, lo cual puede servir para priorizar acciones de seguimiento, retención o expansión.

Respuestas a las 5 preguntas de negocio

1. ¿Cuál es la evolución del MRR y cuántos clientes están en riesgo de cancelar?

El análisis de los datos de clientes e ingresos recurrentes permite monitorear la evolución del MRR y detectar clientes que presentan señales de riesgo. Los estados de suscripción, junto con indicadores como clientes Past Due y churn histórico, facilitan la identificación temprana de posibles cancelaciones y apoyan la implementación de estrategias de retención.

2. ¿Cómo se comporta el pipeline comercial y cuál es la tasa de conversión de oportunidades?

La información proveniente de HubSpot permite visualizar el avance de las oportunidades a través de las distintas etapas del pipeline comercial. Esto facilita el cálculo de tasas de conversión, la

identificación de cuellos de botella en el proceso de ventas y el seguimiento del desempeño comercial de la organización.

3. ¿Qué módulos del producto se utilizan con mayor frecuencia?

Mediante los eventos registrados en PostHog es posible identificar las funcionalidades con mayor nivel de uso dentro de la plataforma. Este análisis permite comprender mejor el comportamiento de los usuarios y detectar aquellas características que generan mayor valor para los clientes.

4. ¿Qué mercados geográficos generan mayor MRR y presentan mayor churn?

La segmentación geográfica de los clientes permite comparar el desempeño de distintos mercados en términos de ingresos recurrentes y cancelaciones. Esta información facilita la identificación de regiones con alto potencial de crecimiento y aquellas que requieren estrategias específicas de retención.

5. ¿Los patrones de uso de la plataforma, como actividad reciente y eventos clave, muestran señales previas al churn, y qué tipo de interacción se asocia con clientes que mantienen MRR activo?

El análisis de los eventos registrados en PostHog permite identificar patrones de comportamiento asociados con la actividad de los usuarios dentro de la plataforma. Al relacionar esta información con los estados de clientes y métricas de ingresos provenientes de ChartMogul, es posible detectar señales que podrían anticipar una cancelación.

Entre las variables analizadas se encuentran la frecuencia de uso, la actividad reciente, la cantidad de eventos registrados y la interacción con funcionalidades específicas del producto. Los clientes con niveles más altos de actividad tienden a mostrar una mayor permanencia dentro de la plataforma y a mantener ingresos recurrentes activos, mientras que una disminución en la interacción puede representar una señal temprana de riesgo.

Este análisis proporciona una base para futuras estrategias de retención y para el desarrollo de modelos predictivos orientados a la detección temprana de churn.

Hallazgos, conclusiones, recomendaciones y limitaciones

Hallazgos

- La integración de múltiples fuentes de datos permite obtener una visión más completa del comportamiento de clientes, ingresos y uso del producto.
- Los estados de suscripción y los indicadores financieros permiten identificar segmentos de clientes con diferentes niveles de riesgo.
- El análisis del pipeline comercial facilita la detección de oportunidades de mejora en el proceso de ventas.
- Los eventos registrados en la plataforma permiten conocer las funcionalidades más utilizadas y comprender mejor la adopción del producto.
- La consolidación de la información en un único modelo analítico mejora significativamente la capacidad de monitoreo y análisis del negocio.

Conclusiones

- Se logró diseñar e implementar una solución de Inteligencia de Negocios que integra información proveniente de múltiples fuentes operacionales.
- El proceso ETL desarrollado permite transformar y consolidar datos de forma reproducible y trazable.
- El modelo dimensional construido facilita el análisis de indicadores estratégicos relacionados con retención, crecimiento y uso del producto.
- Los dashboards desarrollados permiten responder las preguntas de negocio planteadas por la organización.
- La solución proporciona una base sólida para apoyar la toma de decisiones basada en datos.

Recomendaciones

- Implementar un seguimiento periódico de los clientes con señales de riesgo para reducir la tasa de churn.
- Monitorear continuamente los indicadores estratégicos definidos por la organización para evaluar el progreso hacia las metas de diciembre de 2026.
- Promover la adopción de funcionalidades con menor nivel de utilización mediante estrategias de capacitación o mejora de experiencia de usuario.
- Incorporar nuevas métricas y fuentes de información para enriquecer futuros análisis.
- Considerar la implementación de modelos predictivos que permitan anticipar comportamientos de cancelación y oportunidades de crecimiento.

Limitaciones

- El análisis depende de la calidad y disponibilidad de los datos proporcionados por las fuentes operacionales.

-
- Algunas métricas pueden verse afectadas por registros incompletos o inconsistencias presentes en los sistemas de origen.
 - Debido al alcance y tiempo disponible para el proyecto, no se implementaron modelos predictivos avanzados.
 - Los resultados obtenidos representan la información disponible al momento de la extracción y procesamiento de los datos.
 - La solución fue desarrollada con fines académicos y puede requerir ajustes adicionales para una implementación productiva a gran escala.

Enlace a grabación de la presentación

https://drive.google.com/file/d/1JqSi4PWSO-U6NoRtddIE3iCO2nxiVI43/view?usp=drive_link

Referencias

ETL y arquitectura de datos

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). Wiley.

Inmon, W. H. (2005). *Building the data warehouse* (4th ed.). Wiley.

Kleppmann, M. (2017). *Designing data-intensive applications: The big ideas behind reliable, scalable, and maintainable systems*. O'Reilly Media.

Business Intelligence y analítica

Sharda, R., Delen, D., & Turban, E. (2020). *Analytics, data science, and artificial intelligence: Systems for decision support* (11th ed.). Pearson.

Few, S. (2012). *Show me the numbers: Designing tables and graphs to enlighten* (2nd ed.). Analytics Press.

Microsoft. (2024). *Power BI documentation*. Microsoft Learn. <https://learn.microsoft.com/en-us/power-bi/>

Métricas SaaS y retención

Skok, D. (2023). *SaaS metrics 2.0: A guide to measuring and improving what matters*. For Entrepreneurs. <https://www.forentrepreneurs.com/saas-metrics-2/>

Blissing, B., & Jacobsson, A. (2021). *Customer success: How innovative companies are reducing churn and growing recurring revenue*. Wiley.

ChartMogul. (2024). *SaaS churn benchmark report 2024*. ChartMogul. <https://chartmogul.com/reports/churn-benchmark/>

Python para ingeniería de datos

McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media.

VanderPlas, J. (2016). *Python data science handbook: Essential tools for working with data*. O'Reilly Media.

Boto, S., & Fischetti, A. (2021). *Python ETL cookbook: Build robust data pipelines using Python*. Packt Publishing.

APIs REST y extracción de datos

Masse, M. (2011). *REST API design rulebook*. O'Reilly Media.

Stripe. (2024). *Stripe API reference*. Stripe Developers. <https://stripe.com/docs/api>

HubSpot. (2024). *HubSpot API overview*. HubSpot Developers. <https://developers.hubspot.com/docs/api/overview>

PostHog. (2024). *PostHog API documentation*. PostHog. <https://posthog.com/docs/api>

Help Scout. (2024). *Help Scout Docs API v2*. Help Scout Developer. <https://developer.helpscout.com/mailbox-api/>

ChartMogul. (2024). *ChartMogul API reference*. ChartMogul. <https://dev.chartmogul.com/reference>

Metodología Scrum

Schwaber, K., & Sutherland, J. (2020). *The Scrum guide: The definitive guide to Scrum — the rules of the game*. Scrum.org. <https://scrumguides.org/scrum-guide.html>

Cohn, M. (2010). *Succeeding with agile: Software development using Scrum*. Addison-Wesley Professional.